

Universidad Pública de El Alto



MAESTRÍA EN INTELIGENCIA ARTIFICIAL, MACHINE LEARNING Y DATA SCIENCE

MÓDULO: ANÁLISIS Y VISUALIZACIÓN DE DATOS MASIVOS

UNIDAD 2: MINERÍA DE DATOS VISUALES

TAREA 2

Estudiante: Mauricio Alejandro Díaz Tirado

Docente: M.Sc. Juan Regis Muñoz Sirpa

Fecha de Entrega: 30/06/25

1. Comprensión del negocio

Pregunta guía del proyecto

El presente análisis busca responder a la siguiente pregunta fundamental: ¿cómo ha evolucionado la población en los principales países de América Latina desde 1960 y qué patrones de crecimiento emergen al comparar sus trayectorias demográficas? Este estudio se centrará en identificar tanto las tendencias generales de la región como las agrupaciones de países que exhiben comportamientos de crecimiento similares.

Justificación del análisis

Comprender la dinámica poblacional es crucial en el contexto global y regional actual. El crecimiento demográfico impacta directamente en la planificación de políticas públicas, la gestión de recursos naturales, la seguridad alimentaria y el desarrollo económico. Para América Latina una región caracterizada por su diversidad económica y social, identificar patrones de crecimiento permite a los gobiernos y organizaciones internacionales anticipar futuras demandas en infraestructura, salud y educación. Asimismo, este análisis puede revelar oportunidades de inversión y señalar posibles focos de presión migratoria o desafíos de sostenibilidad, proveyendo una base empírica para la toma de decisiones estratégicas.

2. Comprensión de los datos

Para este proyecto se utilizó un conjunto de datos del Banco Mundial que contiene la población total anual desde 1960 hasta 2023. El primer paso consistió en un análisis exploratorio de datos (EDA) para asegurar la calidad y la pertinencia de la información.

Limpieza y preparación inicial de datos

El dataset original contenía metadatos y columnas irrelevantes que fueron eliminadas. Se filtraron los datos para seleccionar 19 países representativos de América Latina, excluyendo agregados regionales. La estructura de los datos se transformó de un formato ancho a uno largo, facilitando así el análisis de series temporales y las visualizaciones subsecuentes. Se verificó la inexistencia de valores nulos en las poblaciones de los países y años seleccionados.

Estadísticas descriptivas

El análisis descriptivo de la población en la región revela una enorme diversidad. La población media de un país latinoamericano a lo largo del período es de aproximadamente 22.7 millones de habitantes, pero con una desviación estándar muy alta que refleja la gran diferencia entre países como Brasil (con más de 211 millones) y Panamá (con poco más de 1.1 millones en 1960).

Visualizaciones iniciales

Para comprender mejor las tendencias, se generaron varias visualizaciones. El gráfico de series temporales para países clave como Brasil, México, Argentina y Colombia muestra una tendencia de crecimiento constante y pronunciado en todos ellos, aunque con diferentes magnitudes.




Figura 1: Evolución de la población en países clave de América Latina (1960-2023)

Un boxplot de la población en 2022 evidencia la asimetría en la distribución, donde Brasil y México se destacan como valores atípicos por su gran tamaño poblacional en comparación con el resto de la región. Finalmente, un heatmap de correlación demostró que las tendencias de crecimiento de todos los países están fuertemente correlacionadas positivamente, lo que indica un patrón de crecimiento regional generalizado.




Figura 2: Heatmap de correlación de las series temporales de población

3. Preparación de los datos

Para el modelado, fue necesario crear un conjunto de datos con características que describieran el comportamiento del crecimiento de cada país. Se calcularon cuatro métricas clave: la población inicial (1960), la población final (2022), el factor de crecimiento total (población final / inicial) y la tasa de crecimiento anual compuesta (CAGR). Estas características permiten comparar el rendimiento demográfico de los países de una manera más justa que simplemente usando sus poblaciones absolutas. Para el modelo de clustering, estas características fueron estandarizadas para evitar que las variables con escalas más grandes dominaran el análisis.

4. Modelado

Regresión para predicción de población futura

Se desarrolló un modelo para predecir la población futura de Brasil. Se comparó una regresión lineal simple con una regresión polinomial de grado 2. La visualización

de los resultados muestra claramente que el modelo polinomial captura la curva de crecimiento de manera mucho más precisa que el modelo lineal, que subestima el crecimiento reciente. La predicción hasta 2040 sugiere una continuación de esta tendencia de crecimiento, aunque a un ritmo ligeramente más lento.




Figura 3: Predicción de la población de Brasil con modelos de regresión

Clustering para agrupar países

Se utilizó el algoritmo k-means para agrupar a los países en función de sus patrones de crecimiento. El método del código sugirió que el número óptimo de clústeres era tres. El resultado es una segmentación de los países en grupos con dinámicas demográficas distintas.




Figura 4: Clusters de países por patrones de crecimiento

5. Evaluación

Evaluación del modelo de regresión

El modelo de regresión polinomial obtuvo un R^2 de 0.9976, indicando un ajuste casi perfecto a los datos históricos de Brasil, muy superior al R^2 de 0.9916 del modelo lineal. El error cuadrático medio (MSE) también fue significativamente menor en el modelo polinomial, validando su superioridad para la predicción.

Evaluación del modelo de clustering

El modelo de clustering con $k=3$ alcanzó un coeficiente de silueta de 0.5711, lo que indica que los clústeres están razonablemente bien definidos y que la separación entre ellos es significativa.

Interpretación de los hallazgos

El análisis de los clústeres reveló tres patrones distintos:

- **Cluster 0 (Crecimiento acelerado):** Compuesto por la mayoría de los países, como Colombia, Perú, Venezuela y Guatemala. Estos países partieron de una base poblacional menor pero han experimentado los factores de crecimiento más altos de la región, con una tasa de crecimiento anual media del 2.15%.
- **Cluster 1 (Gigantes de crecimiento moderado):** Incluye a Brasil y México. Estos países comenzaron con las poblaciones más grandes y, aunque han

crecido enormemente en términos absolutos, su factor de crecimiento y tasa anual (1.89%) son más moderados en comparación con el primer grupo.

- **Cluster 2 (Crecimiento lento y estable):** Incluye a Argentina, Chile, Cuba, El Salvador y Uruguay. Estos países tenían poblaciones iniciales relativamente altas (comparadas con el cluster 0) pero han mostrado el menor factor de crecimiento y la tasa anual más baja (1.04%), indicando una mayor madurez demográfica.

6. Despliegue

Conclusiones y recomendaciones

Este análisis demuestra que, si bien América Latina ha experimentado un crecimiento poblacional generalizado, existen al menos tres dinámicas distintas. La predicción para Brasil sugiere que las grandes potencias de la región continuarán creciendo, aunque de forma más moderada.

Clusters de Crecimiento Poblacional en América Latina (1960-2022)



Figura 5: Mapa de clusters de crecimiento poblacional en América Latina

Recomendaciones:

1. **Políticas diferenciadas:** Los organismos internacionales no deberían tratar a América Latina como un bloque homogéneo. Las políticas de desarrollo deben adaptarse a las realidades de cada clúster: los países del cluster 0 pueden necesitar más inversión en infraestructura y servicios para jóvenes, mientras que los del cluster 2 podrían enfocarse en sistemas de pensiones y salud para una población que envejece.
2. **Foco en el crecimiento acelerado:** Los países del cluster 0 representan tanto una oportunidad (mercados en expansión) como un desafío (presión sobre los recursos). Se recomienda un monitoreo continuo de su trayectoria para asegurar un desarrollo sostenible.
3. **Validación futura:** El modelo de regresión demostró ser efectivo para Brasil, pero debería validarse con datos más recientes y aplicarse a otros países para confirmar si los patrones se mantienen.